MK Praktikum Unggulan Universitas Gunadarma

Mata Kuliah: Praktikum Teknologi Kecerdasan Artifisial (Tingkat 1)

Pertemuan III

Operasi Matriks dengan GPU

NumPy telah menjadi hadiah bagi komunitas Python, Ilmuwan Data, Praktisi Machine Learning dan Ahli Statistik, karena dapat memproses data dalam jumlah besar dalam format matriks dengan cara yang mudah dan efisien.

Bahkan NumPy sudah merupakan langkah signifikan dari Python dalam hal kecepatan. Kapan pun kita menemukan kode Python berjalan lambat, terutama jika kita melihat banyak for-loop, sebaiknya pindahkan pemrosesan data ke NumPy dan biarkan vektorisasi bekerja dengan kecepatan tinggi!

Namun, meski dengan penambahan kecepatan itu, NumPy hanya berjalan di CPU. Dengan CPU konsumen biasanya memiliki 8 core atau kurang, jumlah pemroresan paralel, dan oleh karena itu, jumlah percepatan yang dapat dicapai menjadi terbatas.

Di situlah teman baru kita CuPy berperan!

CuPy adalah library yang mengimplementasikan array NumPy pada GPU Nvidia dengan memanfaatkan library GPU CUDA. Dengan implementasi tersebut, kecepatan paralel yang superior dapat dicapai karena banyaknya core CUDA yang dimiliki GPU.

Antarmuka CuPy bisa dibilang merupakan cerminan dari NumPy dan dalam banyak kasus dapat digunakan sebagai penggantinya langsung. Cukup ganti kode NumPy kita dengan kode CuPy yang kompatibel dan kita akan memiliki kecepatan GPU. CuPy mendukung sebagian besar operasi array yang dimiliki NumPy termasuk pengindeksan, broadcasting, matematika pada array dan berbagai transformasi matriks.

Membuat Array Matriks

Kita akan mencoba melihat perbedaan waktu pembuatan array matriks menggunakan CPU dan GPU.

In [ ]:
```
# Di bawah ini merupakan kode program untuk melakukan instalasi library cupy
# Instalasi HANYA dilakukan JIKA library cupy belum tersedia.

# Untuk menjalankan, hapus tanda '#' pada kode program di bawah ini.
# pip install cupy-cuda110==10.6.0
```

In [ ]:
```
import time
import cupy as cp
import numpy as np
```

In [ ]:
```
s = time.time()
m_cpu = np.random.randint(10, size=(100000,1000))
e = time.time()
print("Waktu CPU :", e - s, "detik")
```

```
Waktu CPU : 1.4515495300292969 detik
```

In [ ]:
```
s = time.time()
m_gpu = cp.random.randint(10, size=(100000,1000))
cp.cuda.Stream.null.synchronize()
e = time.time()
print("Waktu GPU :", e - s, "detik")
```

```
Waktu GPU : 0.06703567504882812 detik
```

Dari hasil di atas, dapat dilihat bahwa semakin besar jumlah array yang dibuat, maka semakin terlihat perbedaan kecepatan antara GPU dan CPU.

Penjumlahan dan Perkalian Matriks

Pada praktikum sebelumnya sudah dibuat program untuk melakukan penjumlahan dan perkalian matriks menggunakan NumPy. Kali ini kita akan melihat perbedaannya dengan menggunakan CuPy.

Penambahan Dua Matriks

1. NumPy

In [ ]:
```
s = time.time()
A = np.random.randint(10, size=(1000,1000))
B = np.random.randint(10, size=(1000,1000))
C = A + B
e = time.time()
print("Waktu CPU :", e - s, "detik")
```

```
Waktu CPU : 0.035001277923583984 detik
```

2. CuPy

In [ ]:
```
s = time.time()
A = cp.random.randint(10, size=(1000,1000))
B = cp.random.randint(10, size=(1000,1000))
C = A + B
cp.cuda.Stream.null.synchronize()
e = time.time()
print("Waktu GPU :", e - s, "detik")
```

```
Waktu GPU : 0.003203868865966797 detik
```

Perkalian Dua Matriks

1. NumPy

In [ ]:
```
s = time.time()
A = np.random.randint(10, size=(1000,1000))
B = np.random.randint(10, size=(1000,1000))
C = A.dot(B)
e = time.time()
print("Waktu CPU :", e - s, "detik")
```

```
Waktu CPU : 1.447923183441162 detik
```

2. CuPy

In [ ]:
```
s = time.time()
A = cp.random.randint(10, size=(1000,1000))
B = cp.random.randint(10, size=(1000,1000))
C = A.dot(B)
cp.cuda.Stream.null.synchronize()
e = time.time()
print("Waktu GPU :", e - s, "detik")
```

```
Waktu GPU : 0.02433037757873535 detik
```

Tugas

Cari dan analisa perbedaan waktu antara penggunaan CPU (NumPy) dengan GPU (CuPy) untuk transpos matriks.

In [2]:
```
import time
import numpy as np
import cupy as cp

# Tentukan ukuran matriks yang cukup besar agar perbedaan terlihat jelas
size = 10000

# --- Pengujian dengan NumPy (CPU) ---
A_cpu = np.random.randint(10, size=(size, size))
s_cpu = time.time()
T_cpu = A_cpu.T
e_cpu = time.time()
print(f"Waktu Transpos CPU : {e_cpu - s_cpu:.6f} detik")

# --- Pengujian dengan CuPy (GPU) ---
A_gpu = cp.random.randint(10, size=(size, size))
s_gpu = time.time()
T_gpu = A_gpu.T
# Penting: Sinkronisasi agar perhitungan selesai sebelum waktu dicatat
cp.cuda.Stream.null.synchronize()
e_gpu = time.time()
print(f"Waktu Transpos GPU : {e_gpu - s_gpu:.6f} detik")
```

```
Waktu Transpos CPU : 0.001738 detik
Waktu Transpos GPU : 0.002317 detik
```

Perhatian! Berikut merupakan cara konversi File IPYNB menjadi File PDF untuk melakukan pengumpulan tugas di Virtual Class. [Video konversi (https://youtu.be/qXELXtnAK7c)](https://youtu.be/qXELXtnAK7c).

Copyright © Pengelola MK Praktikum Unggulan (Praktikum DGX), Universitas Gunadarma

https://www.praktikum-hpc.gunadarma.ac.id/ (https://www.praktikum-hpc.gunadarma.ac.id/)